

Info Juridique Citoyenne

Agent conversationnel de vulgarisation du droit gabonais — droit du travail, foncier et de la famille.

Résumé exécutif

Info Juridique Citoyenne est un agent conversationnel destiné au grand public gabonais. Il répond en français, en langage simple, à des questions juridiques concrètes — en s'appuyant uniquement sur un corpus de textes officiels gabonais (Code du travail, Journal officiel, doctrine) et en citant systématiquement ses sources.

Contrairement à un simple chatbot RAG, l'application est construite comme un **agent avec outils** : le modèle de langage décide lui-même des actions à entreprendre — rechercher dans le corpus, lire un article précis, calculer une indemnité, produire une synthèse ou un rapport — et les enchaîne jusqu'à formuler une réponse fondée et citée.

Interface	Streamlit (chat, streaming, sidebar upload, responsive mobile)
LLM	Groq · llama-3.3-70b-versatile (fallback llama-3.1-8b-instant)
Embeddings	intfloat/multilingual-e5-base via sentence-transformers
Vector store	ChromaDB persistant — collections droit_gabonais + droit_gabonais_uploads
Corpus	PDFs officiels (Code du travail 2021, JO, doctrine) + pages web scrapées
Export	Markdown et PDF via reportlab

Stack technique synthétique. Tous les tunables sont centralisés dans src/config.py.

Ce qui a été réalisé

1. Socle RAG et corpus juridique

- **Ingestion unifiée** de deux types de sources dans une collection Chroma unique (droit_gabonais) :
 - PDFs officiels du dossier data/pdfs/, listés dans un manifest.yaml qui garantit la traçabilité (fichier → domaine → libellé de source).
 - Pages web autoritatives listées dans data/web_sources.yaml, scrapées au moment de l'indexation avec extraction défensive du contenu utile.
- **Chunking** avec limite CHUNK_MAX_CHARS et conservation des métadonnées : domaine, source humaine, numéro d'article quand détecté, type de source.
- **Embeddings multilingues** intfloat/multilingual-e5-base avec gestion rigoureuse des préfixes passage: / query: requis par le modèle — garantit la qualité de retrieval en français.
- **Ingestion idempotente** : la collection est recrée à chaque exécution, les erreurs réseau n'interrompent pas le pipeline.

2. Agent avec boucle d'outils (tool use)

- Remplacement du pipeline RAG linéaire par un **véritable agent Groq** : le LLM sélectionne les outils, consomme leurs résultats, et boucle jusqu'à produire une réponse textuelle streamée.
- **Cinq outils** instrumentés (détaillés ci-dessous).
- **Fallback de modèle** automatique (llama-3.3-70b → llama-3.1-8b) si le modèle principal devient indisponible.
- **Garde-fou d'itérations** (MAX_AGENT_ITERATIONS) pour éviter toute boucle infinie.

3. Outils avancés : synthèse et rapport

- `synthese_document` : produit une synthèse en 5 à 10 points clés, fidèle aux extraits, avec citations intégrées.
- `generer_rapport` : rédige un rapport structuré (contexte, cadre juridique, points clés, démarches pratiques, avertissement).
- Les deux outils sont **utilisables par le LLM** (appel automatique quand la question l'appelle) et **directement par l'utilisateur** via les boutons dédiés sous chaque réponse.
- **Export Markdown et PDF** du rapport, générés côté serveur avec reportlab.

4. Analyse de documents utilisateur

- Upload d'un PDF (contrat, jugement, circulaire) depuis la barre latérale.

- Indexation à la volée dans une **collection éphémère** séparée (`droit_gabonais_uploads`), recrée à chaque nouvel upload et libérée en fin de session.
- Fusion transparente avec le corpus officiel : les questions de l'utilisateur prennent simultanément en compte le corpus permanent et le document téléversé.

5. Interface institutionnelle

- Charte visuelle sobre — bleu marine, typographie Libre Baskerville / Inter, responsive mobile.
- **Empty state** avec suggestions de questions cliquables pour guider le premier usage.
- **Panneau « Aller plus loin »** sous chaque réponse : synthèse, rapport, téléchargement .md et .pdf.
- **Expander « Sources citées »** par réponse, avec badge typé (PDF, web, document uploadé) et score de pertinence.
- **Filtre par domaine** (travail / foncier / famille / tous) via un segmented control.
- **Streaming token par token** pour la réponse de l'agent.

Fonctionnalités actuelles

Pour l'utilisateur final

- **Poser une question juridique en langage courant.** L'agent reformule, recherche dans le corpus, et répond en français vulgarisé.
- **Citer ses sources systématiquement.** Chaque affirmation juridique est rattachée à un article précis au format [Source : ,].
- **Naviguer par domaine :** travail, foncier, famille, ou recherche transverse.
- **Obtenir un calcul concret.** Préavis et indemnités de licenciement selon le Code du travail gabonais (Art. 72 et 75).
- **Générer une synthèse** en bullets à partir d'une réponse existante.
- **Générer un rapport structuré** téléchargeable en Markdown ou PDF, prêt à être partagé avec un avocat ou utilisé comme pièce d'information.
- **Analyser un document personnel** (PDF) en le téléversant ponctuellement.
- **Historique de conversation** persistant pendant la session, effaçable d'un clic.
- **Avertissement légal explicite** rappelé dans la barre latérale et clôturant chaque réponse.

Pour le développeur / le mainteneur

- Architecture modulaire — agent, outils, retriever, loaders, synthesizer découplés.
- Configuration centralisée dans `src/config.py`.
- Ajout d'un nouvel outil : schéma JSON + branche d'exécution + mention dans le prompt système.
- Ajout d'un nouveau PDF : dépôt du fichier + entrée dans `manifest.yaml` + ré-ingestion.
- Ajout d'une nouvelle URL : entrée dans `web_sources.yaml` + ré-ingestion.

Inventaire des outils de l'agent

Outil	Rôle
recherche_juridique	Recherche sémantique dans le corpus (articles pertinents).
lire_article	Lecture du texte complet d'un article par son numéro.
calculer_indemnite	Calcul d'indemnité de licenciement et préavis (Art. 72 & 75 du Code du travail).
synthese_document	Synthèse structurée des règles juridiques sur un sujet donné.

generer_rapport

Rapport complet : contexte, cadre, points clés, démarches.

Invariants techniques à préserver

- **Préfixes e5** (passage : à l'indexation, query : à la recherche) : ne pas router les requêtes par la fonction d'embedding Chroma sous peine de dégrader silencieusement la qualité de retrieval.
- **Fallback Groq** : conserver la double-tentative modèle principal / modèle secours dans GroqLLM.
- **Ingestion destructive** : la collection principale est recrée à chaque exécution — pas de persistance incrémentale, c'est volontaire.
- **Prompt système** : quatre règles non négociables — réponse fondée sur le contexte, citation systématique, reconnaissance de l'hors-périmètre, avertissement légal en clôture.
- **Cache Streamlit** : `get_agent()` est un singleton `@st.cache_resource` qui pré-chauffe le modèle d'embedding pour supprimer le cold start de la première question.
- **Fallback sources côté UI** : si l'agent répond sans appeler d'outil, l'application relance elle-même une recherche pour alimenter les boutons synthèse / rapport.

Limites connues et prochaines étapes

- **Corpus à élargir**. Les domaines foncier et famille annoncés nécessitent encore l'ajout des textes de référence correspondants.
- **Pas de re-ranker**. Un modèle de re-ranking (par exemple `bge-reranker`) appliqué au top-k initial améliorerait la précision des extraits retenus.
- **Recherche purement dense**. Une recherche hybride (BM25 + dense) serait mieux adaptée aux requêtes contenant des numéros d'articles ou des termes juridiques exacts.
- **Découpage non conscient des articles**. Chunking sur caractères, sans alignement sur les frontières d'articles — à terme, parser les numéros et remplir le champ `article` plus finement.
- **Pas de tests automatisés** ni d'observabilité structurée (logs JSONL, feedback utilisateur).
- **Pas d'historique persistant** entre sessions — un refresh du navigateur réinitialise la conversation.

Avertissement

Cet outil fournit des **informations juridiques générales** à vocation pédagogique. Il ne constitue **pas un conseil juridique** et ne se substitue pas à l'expertise d'un avocat ou d'un professionnel du droit. Les textes du corpus doivent être recoupés avec les publications officielles avant tout usage contentieux.